


# LOCALIZACION OPTIMA DE CENTROS DE DISTRIBUCION MEDIANTE MACHINE LEARNING




**SANTIAGO NÁJERA**, un experto multifacético, es un economista, abogado y PhD en Administración de Empresas. Sus conocimientos abarcan maestrías en operaciones, finanzas, estadísticas, gestión de la calidad total, minería y logística.

Con más 20 años de experiencia en la gestión de empresas en diversos sectores, desde consumo masivo hasta finanzas, alimentos y petróleo, así como minería, Santiago aborda temas cruciales como la cadena de suministros, logística, riesgos, finanzas y estrategia. En la actualidad, comparte su vasto conocimiento como consultor, docente y director de tesis en diversas universidades.

- Alen South Lake University - USA
- Cesar Vallejo College - USA
- Keiser University – USA
- Global Humanistic University - Curazao
- EIG Business School - España
- Universidad Internacional de la Rioja - España
- Científica del Sur - Perú
- Pontificia Universidad Católica del Perú
- Universidad Científica del Sur – Perú
- Universidad Autónoma Gabriel René Moreno - Bolivia
- Universidad Pontificia Bolivariana
- Universidad San Francisco de Quito
- Pontificia Universidad Católica del Ecuador
- Escuela Politécnica del Litoral
- Universidad Politécnica Salesiana
- Universidad Internacional del Ecuador
- Universidad Tecnológica Equinoccial
- Universidad de las Américas
- Universidad Central del Ecuador
- Universidad ECOTEC



# LOCALIZACION OPTIMA DE CENTROS DE DISTRIBUCION



**CENTRO DE DISTRIBUCIÓN (CD):** Normalmente, un almacén de productos terminados diseñado para la distribución rápida según la demanda a minoristas (centros de distribución minorista), mayoristas o envíos directos a clientes (centros de cumplimiento de pedidos). Los almacenes de cross-docking son otro tipo de centro de distribución.

**Véase: cross-docking.**

Diccionario APICS 19ª Ed.



# EL ENFOQUE TRADICIONAL

## MÉTODO DEL CENTRO DE GRAVEDAD

Históricamente, hemos utilizado modelos físicos para minimizar la "distancia ponderada" entre la demanda y el suministro.

- ✓ **Objetivo:** Encontrar un punto (X, Y) que minimice costos de transporte.
- ✓ **Limitación:** Asume costos lineales y no considera barreras geográficas reales (ríos, montañas) ni complejidades de tráfico.
- ✓ **Uso:** Bueno para aproximaciones iniciales, insuficiente para precisión moderna.



# LA SOLUCIÓN: MACHINE LEARNING



## APRENDIZAJE NO SUPERVISADO

Utilizamos algoritmos que detectan patrones ocultos en los datos de demanda sin necesidad de etiquetas previas.



## CLUSTERING


La técnica de agrupar puntos de datos (clientes/tiendas) para que los elementos de un grupo sean más similares entre sí que con otros grupos.



## OBJETIVO

Determinar automáticamente las zonas de alta densidad de demanda para colocar CDs estratégicos.

# ALGORITMO K-MEANS



## ¿CÓMO FUNCIONA?

Es un método de partición iterativo que divide los datos en **K** grupos distintos.

**Inicialización:** Selecciona K centroides aleatorios.

**Asignación:** Cada cliente se asigna al centroide más cercano.

**Actualización:** Se recalcula el centroide (promedio) de cada grupo.

**Repetición:** El proceso sigue hasta que los centroides se estabilizan.

# EL MOTOR MATEMÁTICO: DISTANCIAS

## EUCLIDIANA

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Línea recta. Ideal para planos simples, pero ignora la curvatura terrestre.

## MANHATTAN

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Distancia "taxista". Útil para redes de calles tipo cuadrícula urbana.

# REALIDAD GEOGRÁFICA: HAVERSINE

## EL MUNDO NO ES PLANO


Para logística a gran escala, la distancia Euclidiana falla. Necesitamos la fórmula de **Haversine**.

Esta fórmula calcula la distancia del "gran círculo" entre dos puntos de una esfera, crucial para rutas aéreas o marítimas largas y localización precisa de CDs regionales.





# PRE-PROCESAMIENTO DE DATOS



## ESCALADO Y NORMALIZACIÓN

Los algoritmos de distancia como K-Means son sensibles a la escala.

Si mezclamos "Distancia en KM" (0-1000) con "Volumen de Venta" (0-1,000,000), el volumen dominará el cálculo.


- ✓ **Solución:** Normalizar todas las variables a un rango  $[0,1]$  o estandarizarlas (Media 0, Desviación 1).
- ✓ **Resultado:** El algoritmo pondera todas las variables equitativamente.

# OPTIMIZACIÓN: EL MÉTODO DEL CODO

## ¿CUÁNTOS CENTROS NECESITAMOS?

K-Means requiere que definamos "K" (número de centros) de antemano. ¿Cómo sabemos el número óptimo?

Usamos el **Gráfico del Codo**: Calculamos la variación total intra-cluster para diferentes valores de K. El punto donde la curva se "dobla" (el codo) indica el equilibrio óptimo entre costo y cobertura.



# RESUMEN DE OBJETIVOS



## EFICIENCIA

Reducir costos logísticos mediante ubicaciones calculadas matemáticamente.



## VELOCIDAD

Mejorar tiempos de entrega acercando el inventario a los centros de gravedad de la demanda.



## TECNOLOGÍA

Implementar herramientas de Data Science para decisiones estratégicas replicables.